당뇨병 데이터 웨어하우스 프로젝트

BRFSS 2021 기반 · Oracle DB 설계와 머신러닝 예측 · **핵심 요약**

236,378	22	4+1	0.444
응답 데이터 (행)	변수 (컬럼)	정규화 테이블	최적 모델 macro-F1

1. 프로젝트 단계

단계	수행 내용	상태
1단계	주제 선정 · 데이터 전처리 · 정규화 DB(DW) 설계 · Oracle 적재	완료
2단계	Python DB 연동 · 데이터 추출 · 전처리 · 모델링/튜닝 · 암호화 저장	완료
3단계	저장 모델로 예측 · 결과를 DB(ANALYSIS_RESULT)에 저장 · 발표 (예정)	진행

2. 데이터 & 전처리

항목	내용
데이터 출처	CDC BRFSS 2021 (Kaggle Diabetes Health Indicators) · CSV
결측치	0건 — 확인 결과 없음, 추가 처리 불필요
이상치	BMI 60 초과 411건 → 상한값 60으로 조정 (범위 12~60)
데이터 타입	모든 값 정수형 변환 (DB 저장 최적화)
파생변수	**risk_count** — 고혈압·고콜레스테롤·흡연·비만·심장질환·뇌졸중 합산 (0~6)

3. DB 설계 — 정규화 (3NF) · 1:1 관계

테이블	Primary Key	Foreign Key	제약
patient 환자	patient_id	—	CHECK (age, sex)
health_exam 건강검사	**exam_id**	patient_id → patient	UNIQUE CHECK(bmi)
lifestyle 생활습관	**lifestyle_id**	patient_id → patient	UNIQUE
diagnosis 진단결과	**diag_id**	patient_id → patient	UNIQUE CHECK(status)
analysis_result 분석결과	result_id	— (독립 테이블)	분석/예측 결과 저장

▶ 각 자식 테이블은 고유 PK(surrogate key)를 가지고, patient_id는 FK + **UNIQUE**로 분리 → PK/FK 분리 + 중복 방지(1:1 유지). 팀 피드백 반영 설계.

4. 모델링 결과 — 최적 모델: RandomForest

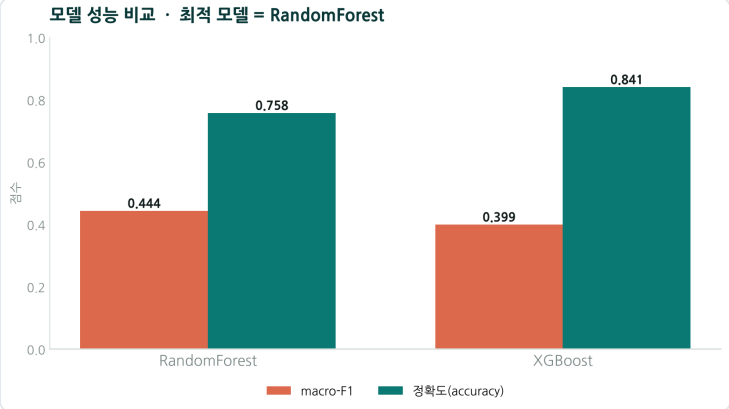


그림 1. 모델 성능 비교 (macro-F1 · 정확도)

모델	macro-F1	정확도
RandomForest 🏆	**0.444**	0.758
XGBoost	0.399	0.841

선정 이유: XGBoost는 정확도가 높지만 다수 클래스(정상)에 치우쳐 당뇨를 잘 못 잡음. 불균형 데이터에서 공정한 지표인 **macro-F1** 기준으로 **RandomForest**를 최종 선택.

튜닝(GridSearch): n_estimators=200, min_samples_leaf=5

5. 평가 & 핵심 인사이트

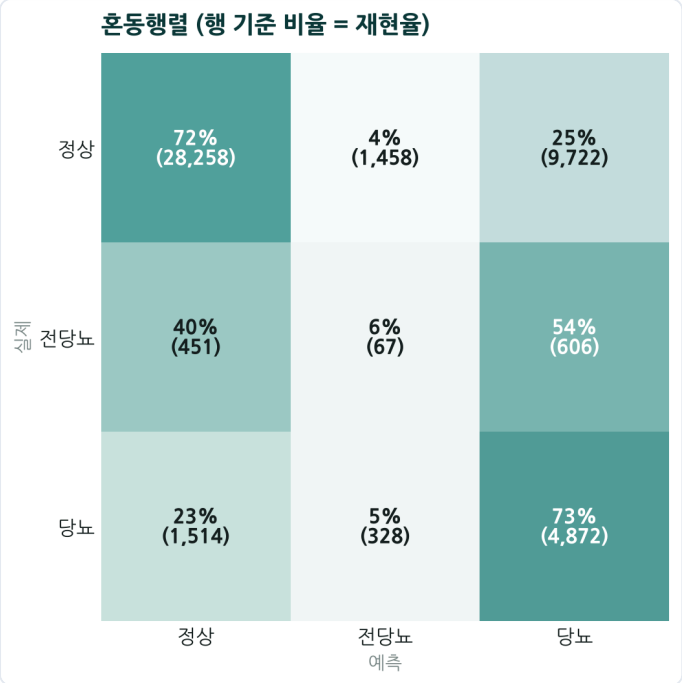


그림 2. 혼동행렬 — 당뇨 재현율 73%

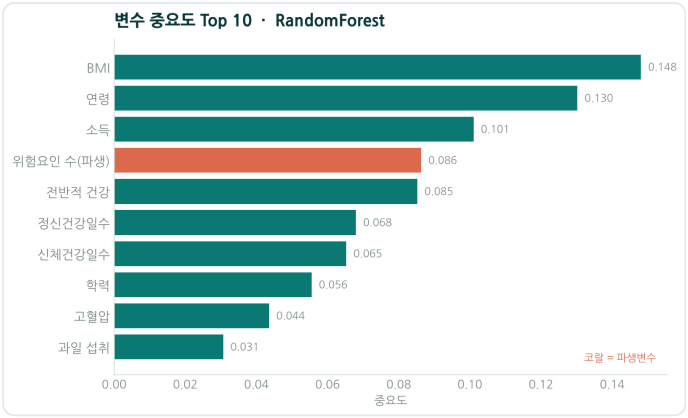


그림 3. 변수 중요도 Top 10

핵심 인사이트	내용
강한 예측 변수	**BMI · 연령 · 소득**이 당뇨 예측에 가장 크게 기여
파생변수 효과	risk_count가 중요도 상위 4위 → 복합 위험도가 유의미함을 확인
모델 성능	당뇨 재현율 73% (실제 당뇨 10명 중 7명 탐지) · 전당뇨는 표본 적어(2%) 한계
최종 저장	최적 모델을 **암호화 파일**(best_model.enc)로 저장 + 불러와 예측 검증 완료